

Projeção de Embeddings BERT

Sistemas de Recuperação de Informação — Atividade a Distância 2

Beatriz Cristina Roecker

Análise de embeddings do corpus de **32 Notícias Brasileiras** utilizando os notebooks:

3_2_1 — Projeção de Documentos | 3_2_2 — Projeção de Tokens

3_2_3 — Tokens e Documentos | 3_2_4 — Sentenças e Documentos

Modelo: **neuralmind/bert-base-portuguese-cased** (BERTimbau Base)

Estratégia: Token [CLS] — Última camada (ESTRATEGIA_EMBEDDING = 0)

Repositório original: <https://github.com/osmarbraz/sri>

Repositório pessoal: <https://github.com/beatrizrckr97/sri-nlp-trabalho>

Descrição do Dataset Utilizado

O corpus utilizado é formado por **32 notícias jornalísticas em Português Brasileiro**, cobrindo economia, política, empresas, governo, saúde, meio ambiente e justiça. Este dataset é **diferente do CSTNews** dos notebooks de exemplo do professor.

Característica	Descrição
Total de documentos	32 notícias jornalísticas
Idioma	Português Brasileiro (pt-BR)
Domínio	Economia, política, empresas, governo, saúde, ambiente, justiça
Modelo BERT	neuralmind/bert-base-portuguese-cased (BERTimbau Base)
Dimensão dos embeddings	768 dimensões
Estratégia	Token [CLS] da última camada (ESTRATEGIA_EMBEDDING = 0)
Total de tokens	468
Total de sentenças	32

1. Projeção de Embeddings — Documentos

O notebook **3_2_1** gera embeddings consolidados para cada um dos 32 documentos. O embedding de cada documento é o vetor do token **[CLS]** da última camada do BERTimbau, capturando o significado semântico global do documento.

Documentos identificados: cada ponto representa um documento rotulado D1–D32. A cor indica o tema (economia=rosa, política=azul, empresas=laranja, governo=verde, saúde=roxo, ambiente=ciano, justiça=vermelho, outros=cinza).




Figura 1: Projeção PCA (esq.) e t-SNE (dir.) dos embeddings de 32 documentos. Documentos D1, D2, D4 e D10 (economia) formam cluster distinto de D9, D12, D18 (política).

Exemplo de documento identificado:

Doc	Tema	Conteúdo
D1	Economia	O presidente Luiz Inácio Lula da Silva assinou hoje em Brasília um pacote de med...
D9	Justiça	O Supremo Tribunal Federal concluiu o julgamento sobre a constitucionalidade da ...
D26	Ambiente	O Brasil sediará a Conferência das Nações Unidas sobre Mudanças Climáticas, a CO...

2. Projeção de Embeddings — Tokens

O notebook **3_2_2** gera embeddings individuais para cada token do corpus (total: 468 tokens). Cada token recebe um embedding contextualizado do BERTimbau, refletindo seu significado no contexto da frase.

Tokens identificados: pontos coloridos por classe gramatical. Nomes próprios (PROPN) aparecem em dourado com rótulo, verbos (VERB) em verde. Tokens de mesma classe gramatical tendem a se agrupar.




Figura 2: Projeção PCA (esq.) e t-SNE (dir.) dos embeddings de tokens. Cores: NOUN=azul, PROPN=rosa/dourado, VERB=verde, ADJ=laranja, ADV=roxo. Nomes próprios como 'Brasil', 'Lula', 'Petrobras' aparecem rotulados.

Exemplos de tokens identificados na projeção:

Token	POS	Documento
Luiz	PROPN	D1
Inácio	PROPN	D1
Lula	PROPN	D1
Silva	PROPN	D1
assinou	VERB	D1
Brasília	PROPN	D1
incluindo	VERB	D1
Banco	PROPN	D2
Central	PROPN	D2
Brasil	PROPN	D2

3. Projeção de Embeddings — Tokens e Documentos

O notebook [3_2_3](#) combina tokens e documentos no mesmo espaço de embedding (500 itens no total). Permite analisar a relação semântica entre palavras individuais e documentos.

Identificação: documentos aparecem como estrelas (★) maiores rotuladas D1–D32, coloridas pelo tema. Tokens são pontos menores coloridos por classe gramatical. Cada documento tende a se posicionar próximo dos tokens que o compõem.




Figura 3: Projeção PCA (esq.) e t-SNE (dir.) de tokens (●) e documentos (★) combinados. Documentos D1–D5 (economia) agrupam-se próximos a tokens financeiros; D9, D12, D18 (política) próximos a tokens governamentais.

4. Projeção de Embeddings — Sentenças e Documentos

O notebook **3_2_4** projeta sentenças e documentos juntos (32 sentenças + 32 documentos). Os embeddings de sentenças são gerados pelo token [CLS] de cada sentença.

Identificação: sentenças aparecem como círculos (●) menores; documentos como diamantes (◆) maiores rotulados D1–D32. A proximidade entre sentença e documento confirma a coerência semântica da representação BERT.




Figura 4: Projeção PCA (esq.) e t-SNE (dir.) de sentenças (●) e documentos (◆). Como cada notícia é uma sentença longa, sentenças e documentos ficam muito próximos, confirmando que o BERTimbau captura o conteúdo semântico de forma consistente.

Exemplos de sentenças identificadas:

Sentença (início)	Tema	Doc
O presidente Luiz Inácio Lula da Silva assinou hoje em ...	Economia	D1
O Banco Central do Brasil decidiu manter a taxa Selic e...	Economia	D2
A Petrobras anunciou lucro líquido de R\$ 23 bilhões no ...	Empresas	D3
O ministro da Fazenda, Fernando Haddad, apresentou ao C...	Economia	D4
A Bolsa de Valores de São Paulo, a B3, registrou alta d...	Economia	D5
O governador de São Paulo, Tarcísio de Freitas, anuncio...	Política	D6
O Instituto Brasileiro de Geografia e Estatística divul...	Outros	D7
A Vale informou que a produção de minério de ferro atin...	Empresas	D8

5. Repositório GitHub

Os notebooks executados e arquivos gerados estão no repositório pessoal. Notebooks na **raiz**; arquivos de projeção na pasta **projecao/**.

Recurso	Localização
Notebooks originais	https://github.com/osmarbraz/sri
Repositório pessoal	https://github.com/beatrizrckr97/sri-nlp-trabalho
Notebooks (raiz)	3_2_1_*.ipynb 3_2_2_*.ipynb 3_2_3_*.ipynb 3_2_4_*.ipynb
Projeções (pasta projecao/)	projector_documento.zip projector_token.zip projector_token_documento.zip projector_sentenca_c
Dataset (pasta data/)	documentos.csv dataset.zip datasetpos.zip