

Processamento de Linguagem Natural

Sistemas de Recuperação de Informação

Beatriz Cristina Roecker

Análise de Corpus de Notícias Brasileiras utilizando os notebooks

1_1_Segmentacao_Limpeza_v1.ipynb | 1_2_GerarPOS_v1.ipynb

1_3_NER_spacy_v1.ipynb | 2_1_AnaliseDados_v1.ipynb

Repositório dos notebooks originais: <https://github.com/osmarbraz/sri>

Repositório pessoal: <https://github.com/beatrizrckr97/sri-nlp-trabalho>

1. Descrição do Texto Utilizado

O corpus utilizado neste trabalho é composto por **32 documentos** de notícias jornalísticas em língua portuguesa sobre temas de **economia, política e sociedade brasileira**. Cada documento corresponde a uma notícia sintética inspirada em coberturas de grandes veículos de comunicação nacionais, abordando tópicos como decisões do Banco Central, resultados financeiros de empresas, votações no Congresso Nacional, políticas públicas e eventos internacionais.

O corpus apresenta características relevantes para tarefas de PLN: rico em **entidades nomeadas** (pessoas, organizações, locais e valores monetários), uso de **vocabulário técnico-jornalístico**, variação lexical e sintática entre os documentos, e densidade informacional elevada.

Característica	Valor
Total de documentos	32
Domínio	Notícias brasileiras (economia, política, sociedade)
Idioma	Português (pt-BR)
Média de tokens por documento	20.8
Total de tokens no corpus	665
Vocabulário único (com stopwords)	338

Exemplo de documento do corpus:

"O presidente Luiz Inácio Lula da Silva assinou hoje em Brasília um pacote de medidas para estimular a economia brasileira, incluindo investimentos em infraestrutura e geração de empregos."

2. POS Tagging – Exemplo de Sentença

O POS Tagging classifica cada token com sua classe gramatical. Foi utilizado um tagger baseado em regras linguísticas para o Português Brasileiro, compatível com o notebook **1_2_GerarPOS_v1.ipynb**.

Sentença analisada:

"O presidente Luiz Inácio Lula da Silva assinou hoje em Brasília um pacote de medidas para estimular a economia brasileira, incluindo investimentos em infraestrutura e geração de empregos."

Resultado do POS Tagging:

Token	Tag	Classe Gramatical
O	ART	Artigo
presidente	SUBST	Substantivo
Luiz	PROPN	Nome Próprio
Inácio	PROPN	Nome Próprio
Lula	PROPN	Nome Próprio
da	PREP	Preposição
Silva	PROPN	Nome Próprio
assinou	V	Verbo
hoje	ADV	Advérbio
em	PREP	Preposição
Brasília	PROPN	Nome Próprio
um	ART	Artigo
pacote	SUBST	Substantivo
de	PREP	Preposição
medidas	SUBST	Substantivo
para	PREP	Preposição
estimular	SUBST	Substantivo
a	ART	Artigo
economia	SUBST	Substantivo
brasileira	SUBST	Substantivo
,	PUNCT	Pontuação
incluindo	V	Verbo
investimentos	SUBST	Substantivo
em	PREP	Preposição
infraestrutura	SUBST	Substantivo
e	CONJ	Conjunção
geração	SUBST	Substantivo
de	PREP	Preposição
empregos	SUBST	Substantivo
.	PUNCT	Pontuação

3. NER – Reconhecimento de Entidades Nomeadas

O NER identifica e classifica entidades como pessoas, organizações, locais e valores. Foi utilizada abordagem baseada em padrões regex, compatível com o notebook **1_3_NER_spacy_v1.ipynb**.

Sentença analisada:

"O ministro da Fazenda, Fernando Haddad, apresentou ao Congresso Nacional o novo arcabouço fiscal, que prevê meta de déficit zero para 2025."

Entidades identificadas:

Entidade	Tipo	Descrição
Fernando Haddad	PESSOA	Nome de pessoa física
Congresso Nacional	ORGANIZACAO	Empresa, órgão ou instituição

Tipos de Entidade Reconhecidos:

Tipo	Descrição	Exemplos no Corpus
PESSOA	Nome de pessoa física	Fernando Haddad, Lula, Marina Silva
ORGANIZACAO	Empresa, órgão ou instituição	Petrobras, Banco Central, STF
LOCAL	Cidade, estado, região ou país	São Paulo, Brasília, Nordeste
VALOR	Valor monetário ou percentual	R\$ 23 bilhões, US\$ 2 bilhões

4. Análise de Dados do Corpus

Resultados da análise estatística e linguística do corpus completo, conforme o notebook [2_1_AnaliseDados_v1.ipynb](#).

4.1 Estatísticas Gerais

Métrica	Total de Tokens	Tokens sem Stopwords
Mínimo por doc.	17	10
Máximo por doc.	28	18
Média por doc.	20.8	12.2
Total no corpus	665	392

4.2 Distribuição de Tokens por Documento




Figura 1: Quantidade de tokens por documento, com e sem stopwords.

4.3 Boxplot – Dispersão dos Tokens




Figura 2: Boxplot da distribuição de tokens por documento.

4.4 Top 20 Palavras Mais Frequentes




Figura 3: As 20 palavras de maior frequência no corpus (sem stopwords).

4.5 Distribuição das Classes Gramaticais (POS)




Figura 4: Distribuição absoluta e proporcional das classes gramaticais.

4.6 Análise de Entidades Nomeadas (NER)




Figura 5: Distribuição de tipos de entidade e top entidades no corpus.

5. Repositório GitHub

Os notebooks executados e os arquivos gerados estão disponíveis nos repositórios abaixo.

Recurso	Link
Notebooks originais (Prof. Osmar Braz)	https://github.com/osmarbraz/sri
Repositório pessoal (Beatriz Cristina Rochedo)	https://github.com/beatrizrckr97/sri-nlp-trabalho